

mini-vlm

基于 VLM 的图像分类、 问答与目标检测

从零理解视觉语言模型（Vision-Language Model）的原理与使用范式

基于开源项目 [jingyaogong/minimind-v](#)（65M 超小多模态模型）

面向对象：大四本科生 · 课程：人工智能与计算机视觉

目标


前置

原理

实现

实战

先看一个例子：同一个模型，能做多少事？



狗

狗在画面中央的草地上，正在晒太阳。

[0.298, 0.421, 0.563, 0.815]

这张图的主体是什么？只回答类别名。

狗在图中的什么位置？它在做什么？

定位图中的狗，输出边界框 [x1,y1,x2,y2]。

注意：以上三个回答来自**同一个模型**，我们只是换了**提问方式**。这就是视觉语言模型（VLM）。

输入：一张照片 

本课程设计的目标：亲手把「图像 + 提问 → 回答」的链路跑通 —— 包括**图像分类**、**视觉问答**、**目标检测**三个任务，并理解它背后的原理。

课程导览：我们将沿着这条路线走

01 实验目标 三大任务的数据集构建与评测指标	02 前置知识 分类 / 问答 / 检测的任务定义、数据集、经典模型	03 VLM 基础 Transformer → VLM 架构 → 训练方法 → 改进	04 VLM 实现三任务 统一的「生成式」解题范式	05 minimind-v 实战 代码库、微调方法与动手路线
--	---	---	--	---

学习原则：**不追求绝对正确率**，重在理解 VLM 的基础知识与「用 VLM 解决问题」的范式。

建议的学习姿势：每一页都问自己 —— 这一步的输入是什么、输出是什么、谁在学习？

右侧的五个彩色标签就是这份讲义的"章节索引"，放映时随时指示当前所在章节。


为什么用 VLM 做这三个任务？

传统计算机视觉

- 一个任务训练一个专用模型：
- 分类：CNN + softmax 分类头
 - 检测：专门的检测头输出框
 - 问答：又一套融合模型
- 换任务 = 换结构、重新训练。

VLM 范式

一个模型 + 一段自然语言指令，通过"生成文本"统一完成所有任务。换任务 = 换 prompt，或微调同一份数据格式。



任务被统一为「图像 + 文本 → 文本」的条件生成

- 模型可**零样本/少样本**迁移到新任务：改 prompt 即可，不必重训一个"头"；
- 输出是自由文本，**答案可解释、格式可自定义**（甚至输出坐标）；
- 代价：推理比专用小模型慢，输出格式需要约束与解析。



实验目标

构建分类、问答、目标检测三个任务的数据集，并设计评测指标

本讲路线：任务书 → 整体实验流程 → 三周里程碑 → 三个数据集怎么建 → 三类指标怎么算 → 交付与评分

目标
前置
原理
实现
实战

课程设计任务书（总览）

任务	输入 → 输出	数据集构建	评测指标
图像分类	图像 + "图中主体属于哪个类别？" → 类别名	选定 5~10 个类别，每类 ≥50 张图像，整理为 (图像, 类别) 对	Accuracy（归一化后精确匹配）
视觉问答	图像 + 自然语言问题 → 自由文本答案	围绕图像构造 ≥100 条 (图像, 问题, 参考答案)	Exact Match、VQA-Acc、关键词命中率
目标检测	图像 + "找出图中的 X" → 边界框坐标文本	≥100 张图像 + 人工标注框，转为 (图像, 指令, 坐标文本)	IoU、Acc@IoU≥0.5

- 统一底座：所有任务都在 **minimind-v** 上完成（先推理体验，再微调提升）；
- 必须产出：**数据集（含构建脚本与说明）、微调权重、评测脚本与结果、实验报告**；
- 鼓励对比实验：**微调前 vs 微调后、不同 prompt、不同冻结策略**。

整体实验流程：一条五步走 pipeline



- 先建**零样本基线**再微调 —— 没有基线就无法回答"微调有没有用、有多大用"；
- test 集只在第 ④ 步使用**一次**，中间调参只看 val —— 这是机器学习的基本纪律。

组织形式：三周里程碑与检查点

W1

环境与基线

跑通 minimind-v 推理；为三任务各设计 2~3 版 prompt 做零样本测试；在 test 上记录基线指标

W2

数据与微调

收集/标注数据并转 parquet；完成一轮 SFT；在 val 上确认格式遵循率达标

W3

评测与报告

微调前后对比 + 消融实验；错误分析归类；撰写报告、准备答辩

中期检查点（第 1 周末）

提交：零样本结果表 + 数据集 10 条样例 + 标注规范草案。目的：把"数据集不合格、基线没跑通"这类风险暴露在前 1/3。

常见进度陷阱

① 跳过基线直接微调 → 无法回答"微调有没有用"；② 数据集没划分就先训练 → 返工；③ test 提前用于调参 → 指标失真。请按里程碑顺序推进。

目标
前置
原理
实现
实战

数据集构建：四个通用要求

① 来源与规模

可从公开数据集抽样（CIFAR / ImageNet 子集、VQA v2 子集、Pascal VOC / COCO / RefCOCO 子集），也可自行拍摄收集。**规模不求大**：每任务 100~500 条即可跑通完整流程。

② 划分

train / val / test 按 **8:1:1** 划分，按图像去重（同一张图不要同时出现在 train 和 test）。test 绝不参与训练与调参。

③ 格式：与 minimind-v 对齐

整理为 `conversations`（对话 JSON）+ `image_bytes`（JPEG 二进制）两列，存为 parquet，与仓库 `sft_i2t.parquet` 一致：


```
[
  {"role": "user", "content":
    "<image>\n图中主体属于哪个类别? "},
  {"role": "assistant", "content": "金毛寻回犬"}
]
```

④ 质量控制

标注一致性（同类问题同类表述）、类别均衡、剔除模糊/歧义样本；**写明标注规范**是报告的一部分。可用强模型（GPT-4o 等）生成初稿再人工校对，但要在报告中说明。

- 目标
- 前置
- 原理
- 实现
- 实战

示例①：分类数据集长什么样



(图像, 类别) 对 —— 每类 ≥50 张，类别均衡


两种可选来源：

- 公开数据集抽样：CIFAR-10（10 类、32×32）每类抽 50~100 张，最省事；
- 自选场景：如"校园里的 5 类物体"（自行车/外卖柜/猫/共享单车/教学楼），自己拍摄，更有成就感也更适合写报告。

转成指令格式（用于微调）：

```
{"role": "user", "content": "
```

示例②：问答数据集长什么样




问题类型	问题	参考答案
属性	图中的狗是什么颜色的？	棕色 / 金黄色
计数	图中有几只狗？	一只
空间关系	太阳在狗的什么方位？	右上方 / 头顶
场景推断	这张照片大概是什么天气？	晴天

围绕每张图设计 2~4 个问题

- **问题类型要覆盖：**属性、计数、空间关系、场景推断各占一些 —— 小模型在计数/空间上明显更差，按类型分别统计准确率是报告的好素材；
- 每题给 **1~3 个参考答案**（容忍同义表述）；
- 可先用强模型生成初稿，再**人工校对**（体验"数据蒸馏"流程）。

示例③：检测数据集长什么样

标注 → 指令对的转换：



```
# 标注文件 (Labelme 输出)
{"label": "dog",
 "points": [[86.5, 109.4], [162.6, 234.5]],    # 像素坐标
 "imageWidth": 290, "imageHeight": 271}

# 归一化到 0~1 (与分辨率解耦!)
[x1, y1, x2, y2] = [0.298, 0.404, 0.561, 0.865]

# 转成指令对
{"role": "user", "content":
  "<image>\n定位图中的狗，输出 [x1,y1,x2,y2]，0~1 归一化。"}
{"role": "assistant", "content": "[0.298, 0.404, 0.561, 0.865]"}

```

用 Labelme / CVAT 标注边界框

- 多目标图像：一条样本可在答案里输出**多个框 + 类别**；
- 问句引用**文本描述**（“找出穿红衣服的人”）就是视觉定位（Grounding）任务的标准形式。

评测指标①：分类 Accuracy 与混淆矩阵

计算步骤：

- 1. 收集模型对每个 test 样本的**输出文本**；
- 2. **归一化**：去空格/标点、统一大小写、同义词映射（"小狗"→"狗"）；
- 3. 与真值标签精确匹配，统计正确数。

Accuracy = 预测正确数 / 总样本数

输出**无法解析**出类别名的样本要单独计数：**format failure rate**（格式失败率），它反映模型"听懂格式要求"的程度。

混淆矩阵：错误结构一目了然

		预测 →			
		猫	狗	汽车	船
↑ 真值	猫	38	9	2	1
	狗	11	35	3	1
	汽车	1	2	44	3
	船	2	1	4	43

绿色对角线 = 预测正确；红色块揭示"猫↔狗"最易混淆

评测指标②：问答（开放答案怎么打分？）

Exact Match

归一化后与参考答案**完全一致**得 1 分，否则 0 分。

- ✓ 简单客观
- ✗ 太严苛："一只狗" vs "1 只小狗" 算错

VQA-Acc（经典定义）

VQA 数据集让 10 个人标注同一题，模型答案被越多人认同分越高：

$$Acc = \min(1, \text{认同人数} / 3)$$

单人标注场景可用多个参考答案近似。


实用替代方案

- 关键词命中率**：参考答案的关键词是否出现在生成中；
- 人工评分**：抽样按 0 / 0.5 / 1 打分，两人背对背评分并报告一致性。

不管用哪个指标，都必须做的一件事：按问题类型分桶统计

属性 90% / 计数 40% / 空间关系 55% / 场景推断 75% —— 这样的**分桶结果**远比一个总的 65% 有信息量，也最能体现你对模型的理解。

评测指标③：IoU 与 $\text{Acc@IoU} \geq 0.5$



$$\text{IoU} = \text{黄色交集面积} \div \text{两框并集面积}$$

$$\text{IoU} = \text{Area}(\text{预测} \cap \text{真值}) / \text{Area}(\text{预测} \cup \text{真值})$$

- $\text{IoU} = 1$ ：完美重合； $\text{IoU} = 0$ ：完全不相交；
- 常用判定阈值： $\text{IoU} \geq 0.5$ 即认为"检测正确"（grounding 任务标准口径）；
- 报告两个数： $\text{Acc@IoU} \geq 0.5$ （定位正确的样本比例）与平均 IoU （定位精细程度）；
- 坐标解析失败（模型没输出 4 个数）单独计数 —— 与分类的 format failure 同理。

直觉校准

两个"看起来差不多、都框住了狗"的框，IoU 通常只有 0.6~0.8 —— IoU 比人眼直觉严格。所以 65M 小模型拿到 0.3 以上的 Acc@0.5 就值得肯定。

交付物与评分建议

交付物清单


- 三个任务的数据集（含构建/转换脚本与 README、标注规范）
- 微调后的模型权重 + 训练配置
- 评测脚本与**可复现**的评测结果
- 实验报告（PDF）：原理理解 + 实验过程 + 结果分析
- （可选）WebUI 演示 / 演示视频

评分维度（建议）

- 数据集构建质量与规范性 20%
- 流程完整度：三个任务全部跑通 25%
- 结果分析与错误归因的深度 25%
- 对 VLM 原理的理解（报告 + 答辩） 20%
- 创新尝试（prompt 工程、冻结策略对比等） 10%

再次强调：**指标高低不是主要评分依据**。65M 的小模型出错是正常的，能**解释**为什么错、错在哪，才是本课程设计的核心收获。

小结：我们已经定义了“做什么、怎么评”



到此，任务书已经完整：**输入输出、数据集规格、评测指标、交付要求**一应俱全。

但动手之前，值得先回答三个问题：**这些任务传统上是怎么解决的？经典模型有哪些？它们为什么不够用？**——只有看清旧范式的边界，才能真正理解VLM 的价值。

↓ 进入第 ② 讲：前置知识

02


前置知识

分类、问答、目标检测：任务定义 · 数据集 · 经典模型

本讲路线：三个任务各自"解决什么问题、用什么数据、模型怎么演进" → 传统方法的天花板在哪里 → 为什么需要 VLM

- 目标
- 前置**
- 原理
- 实现
- 实战

任务定义：整张图 → 一个标签



f : 图像 $\rightarrow$ C 个预定义类别之一

- **单标签分类**：每张图恰属一类（本课程设计采用）；**多标签**：一张图可同时有多个标签；
- 传统做法：模型最后接一个 **softmax 分类头**，输出 C 维概率分布，取 **argmax**；
- 评测：**Top-1 Acc**（最高概率类命中）、**Top-5 Acc**（前 5 高概率中含真值，ImageNet 常用）。

关键认知

分类是**输出空间最小、最容易评测**的视觉任务 —— 它也是检验任何新模型"能不能看图"的第一块试金石。


经典数据集：难度逐级递增

MNIST (1998)



手写数字，28×28 灰度，10 类，6 万训练图。深度学习的"Hello World"。

CIFAR-10/100 (2009)



32×32 彩色自然图像，10/100 类，5 万训练图。小尺寸、类内差异大，课程设计抽样的首选。

ImageNet (2009)

128 万张图、1000 类、高分辨率。2012 年 AlexNet 在此夺冠，**引爆深度学习革命**；至今仍是预训练的事实标准。

ILSVRC 竞赛推动了 AlexNet → VGG → GoogLeNet → ResNet 的军备竞赛。


规律：数据集规模每上一个台阶，就催生一代新模型 —— "数据成就模型"在视觉领域反复上演，VLM 时代同样如此。

模型演进：一条 25 年的时间线



- **残差连接** ($y = F(x) + x$) 解决了深层网络梯度消失，是今天所有大模型的基础设施；
- **ViT** 证明：把图像切成 patch 当 token 处理，纯 Transformer 也能称霸视觉 —— 为 VLM 埋下伏笔；
- **CLIP** 证明：用 4 亿图文对做对比学习，视觉特征可以天然“懂语言”，不用训练就能分类。

插页：CNN 的直觉（为理解 ViT 做铺垫）




- **卷积**：一个小窗口（卷积核）在图像上滑动，检测局部模式（边缘→纹理→部件→物体）；
- **池化/下采样**：逐步压缩尺寸，让越深的层“看”到越大的视野、越抽象的概念；
- CNN 内置了两个假设：**局部性**（相邻像素相关）与**平移不变性**（猫在左上角和右下角都是猫）。

ViT 的颠覆

ViT **放弃**这两个假设：把图像切成 16×16 的 patch，拉平成 token 序列丢给 Transformer，让注意力自己去学“哪些 patch 相关”。数据足够多时，学得比人工假设更好 —— 这也统一了图像与文本的处理方式。

VQA：看得懂，还要答得对



图中有几只狗？

一只。

天气怎么样？

晴天，太阳很大。

任务定义： 给定图像 + 关于图像的自然语言问题，输出答案。它是**视觉理解** + **语言推理**的联合测试。

难点：

- 问题决定"看哪里" —— 问颜色要看物体表面，问数量要数清楚；
- **语言先验陷阱：** 模型可能不看图，凭"狗通常是棕色的"来猜 —— 好数据集（如 VQA v2）专门设计对抗样本惩罚这种行为；
- 答案开放，评测比分类难（见第 ① 讲指标设计）。

经典数据集：


- **VQA v1/v2：** COCO 图像 + 人工问答，领域基准；
- **GQA：** 基于场景图的组合推理问答（"大狗左边的东西是什么颜色？"）；
- **TextVQA / DocVQA：** 需要读懂图中文字才能回答。

VQA 方法演进：从“拼接特征”到“统一生成”



- VQA 是 VLM 最自然的应用形态 —— minimind-v 的 SFT 数据本身就是百万级图文问答；
- 课程设计的问答任务重点不在“让模型会问答”（它本来就会一点），而在数据集构建与评测设计。

任务定义：有什么 + 在哪里



输出：每个目标的 框 + 类别 + 置信度

- **边界框**：(x, y, w, h) 或 (x1, y1, x2, y2)，定位目标的矩形；
- **IoU**：预测框与真值框的交并比（第 ① 讲已图解），衡量定位质量；
- **AP / mAP**：按置信度排序画 Precision-Recall 曲线，曲线下面积为 AP，各类别均值为 mAP —— 检测领域主指标；
- **NMS**：非极大值抑制，同一目标的多个重叠框只留置信度最高的。

经典数据集：

- **Pascal VOC**：20 类、~1 万图，小而经典（适合课程设计抽样）；
- **MS COCO**：80 类、33 万图，检测领域的"ImageNet"。

检测模型谱系：五代演进

路线	代表模型	核心思想	特点
两阶段	R-CNN → Fast/Faster R-CNN	先提候选区域（Region Proposal），再逐区域分类+回归框	精度高、速度慢
一阶段	YOLO 系列 / SSD	图像划网格，每个网格直接预测框与类别	快，可实时
Anchor-free	FCOS / CenterNet	抛弃预设锚框，直接预测中心点与尺寸	设计更简洁
Transformer	DETR 系列	把检测看成 集合预测 ：object query 与图像做注意力，二分匹配 免 NMS	端到端、免手工后处理
开放词汇	Grounding DINO / VLM	用 文本描述 指定要检测的目标（"穿红衣服的人"）	类别不再封闭

为什么传统检测器不够用？

类别集合在**训练时固定**：COCO 检测器只会检测那 80 类，想检测"外卖柜"就得重新收集数据训练。而 VLM 让「用语言描述任意目标 → 输出它的位置」成为可能 —— 这正是本课程设计检测任务的切入点（视觉定位 / Grounding）。

目标
前置
原理
实现
实战

三个任务的关系：理解深度的阶梯

图像分类

这张图

是什么？整图 → 一个标签 目标检测 有什么 + 在哪里？多个框 + 类别 视觉问答 关于图像的任意问题：理解与推理

分类

粒度最粗，输出空间最小，评测最容易。

检测

多了定位维度，评测要同时看类别对与位置准（IoU）。

问答

输出空间开放，涉及计数、属性、关系、常识，评测最难标准化。

传统方法：三个任务三套模型。**VLM：一个模型、三种 prompt** —— 输出都是文本序列。这条由易到难的阶梯，也正是课程设计三个任务的**推荐完成顺序**。

传统范式的三块天花板

① 任务专用结构

分类有分类头、检测有检测头、问答有融合模块 —— 每换一个任务，就要换一套结构、重新收集数据、重新训练。

② 封闭的输出空间

分类器的类别、检测器的 80 类、VQA 的答案词表，**全部在训练时固定**。想识别新类别？重新标注、重新训练。

③ 听不懂指令

不能用自然语言告诉模型“今天帮我找穿红衣服的人”；模型也没有常识与推理能力，无法回答开放式问题。

要同时突破这三块天花板，需要的是：**一个能理解语言指令、输出自由文本、视觉与语言共享一套架构的模型** —— 这正是 VLM。

VLM 的地基是 Transformer。下一讲我们从“机器如何表示一个 token”开始，一步步把这座大厦搭起来。

↓ 进入第 ③ 讲：VLM 基础知识

03

VLM 基础知识

Transformer · VLM 架构 · 训练方法 · 改进方向

本讲路线： token 是什么 → 注意力 → Transformer → LLM 如何"学习" → 图像如何变成 token → 三段式 VLM 架构 → 怎么训练


- 目标
- 前置
- 原理**
- 实现
- 实战

第一步：机器不认识文字，只认识向量

token（词元）：把文本切成的最小处理单元（可以是字、子词或词）。

```
"这只狗很可爱"  
→ [这, 只, 狗, 很, 可, 爱]  
→ [1024, 215, 3881, 77, 930, 452] # 查表得到 id
```

embedding（嵌入）：每个 id 查表得到一个高维向量（如 768 维），语义相近的词向量也相近 —— 语义被“装进”了几何空间。



文本序列 → id 序列 → 向量矩阵 (seq_len × 768)

记住这个画面：模型处理的一切都是“一排向量”。后面我们会看到 —— 图像也可以变成这样一排向量，这就是 VLM 的全部秘密。

自注意力：让每个词“看见”其他词


读这句话：“这只狗没有去追那只猫，因为它吃饱了。”

"它"指谁？人一眼知道是**狗**。机器怎么知道？—— 让"它"这个 token 去**查询**句子里所有 token，算一算和谁关系最大。

自注意力（Self-Attention）：序列中每个 token 都与所有 token 计算相关性权重，再按权重把大家的信息**加权混合**进来，从而建模长程依赖。

"因果掩码"：生成式模型里，每个位置只能看它**左边**的 token（不许偷看未来），保证逐字生成的自回归特性。

注意力权重热力图（行=谁在看，列=看谁）



"它"这一行：**狗** 的格子最亮 → 指代消解自动完成

注意力怎么算：Q、K、V 三个角色

每个 token 的向量被线性变换成三份，各司其职：

- Q (Query 查询)："我想找什么"
- K (Key 键)："我是什么" (被检索的名片)
- V (Value 值)："我携带的信息"

用 Q 和所有 K 算相似度 → softmax 归一化成权重 → 对 V 加权求和：

$$\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d}) \cdot V$$

除以 $\sqrt{d}$ 防止内积过大导致 softmax 饱和；所有 token 的 Q/K/V 拼成矩阵，一次矩阵乘法完成全部计算（高度并行）。

Multi-Head Attention

把向量切成 h 份，并行做 h 组注意力：一组关注语法、一组关注指代、一组关注位置..... 各学各的关系，最后拼接 —— 相当于"多角度互相看"。

一个 Transformer Block

Multi-Head Attention → 残差+LayerNorm → FFN（两层 MLP）→ 残差+LayerNorm。把 N 个 block 堆起来（minimind 是 8 层），就是完整模型。残差连接让深层堆叠可训练（ResNet 的遗产）。

为什么它能统一一切？

输入只要求是任意 token 序列 —— 文本 token、图像 patch token、语音 token 一视同仁。这就是 VLM 架构的地基。

LLM 如何学习：下一个 token 预测

训练目标：给前面所有 token，预测下一个。海量文本上的这一简单目标，逼出了语言与世界知识：

$$P(x_1 \dots x_n) = \prod_i P(x_i \mid x_1 \dots x_{i-1})$$

推理（生成）：一个 token 一个 token 往外蹦，直到输出结束符：

输入："这只狗很" → 模型：可

输入："这只狗很可" → 模型：爱

输入："这只狗很可爱" → 模型：<eos> 停止

两阶段训练：

阶段	数据	学到什么
预训练 Pretrain	海量无标注文本	语言能力 + 世界知识
指令微调 SFT	(指令, 回答) 对	听懂人话、按指令回答

「LLM 与"语言"关系不大，更确切的名字是**自回归 Transformer**——一种建模 token 流的通用技术。token 可以代表文本、图片、音频、动作..... 任何东西。」

这是 VLM 的思想根源：图像只要能变成 token 序列，就能交给同一个 Transformer 做同样的"下一个 token 预测"。

目标

前置

原理

实现

实战


核心比喻：图像是一门外语，我们需要一本词典

minimind-v 作者的精彩比喻：

- 对 LLM 来说，图像就像一门**从未见过的"外语"**。要让它理解图片，只需两件事：
- 1

一本擅长翻译图片的「**外语词典**」—— Visual Encoder，把图像翻译成 LLM 能理解的"语言"（视觉 token）；
- 2

微调 LLM，让它和这本"词典"度过磨合期，学会理解翻译过来的视觉信息。




音频、视频、点云..... 任何模态接入 LLM 都是同样的配方 —— 这就是为什么 VLM 架构如此通用。

VLM 的通用架构：三段式



LLaVA、Qwen-VL、MiniCPM-V、InternVL、minimind-v —— 都是这个骨架，差异在组件选型、数据与训练策略

① 视觉编码器：图像怎么变成 token



一张图 = 64 个视觉 token（和“一排词向量”长得一样！）


过程：

- 1. 图像 resize 到 256×256，按 32×32 切成 8×8 = 64 个 patch；
- 2. 每个 patch 拉平 + 线性映射成一个向量，加上位置编码；
- 3. 64 个向量序列送进 ViT 做自注意力（patch 之间互相“看”）；
- 4. 取 encoder 层输出：**64 × 768 的特征矩阵**。

回头看上一讲的伏笔

CNN 靠“局部性”假设，ViT 靠注意力自己学 patch 间关系 —— 而 VLM 直接把 ViT 的输出当作一排 token。图像和文本在形式上被统一了。

这本“词典”从哪来：CLIP 的图文对比学习



对比损失 InfoNCE：配对的图文向量靠近，不配对的远离

CLIP（2021, OpenAI）：

- 用 4 亿 (图像, 文本) 对训练图像编码器 + 文本编码器，各自输出一个向量；
- 训练后，两个编码器的输出落在**同一个语义空间**—— 图像向量和"它的描述"的文本向量天然接近；
- 副产品：**零样本分类**—— 把 "a photo of a {类别}" 的文本向量和图像向量比相似度即可分类，不需要分类头、不需要训练。

为什么 VLM 都爱用 CLIP 系编码器？

特征空间**天然与语言对齐**（训练时就见过文本），投影层学起来事半功倍；表征通用、开放词汇；开箱即用、冻结即可，省去昂贵的视觉预训练。

SigLIP：CLIP 的高效改进版（minimind-v 的选择）

改进点：

- CLIP 用 **softmax** 对比损失：需要全局归一化，大 batch 才稳定；
- SigLIP 改为 **sigmoid 逐对二分类损失**：每对图文独立判断"配/不配"，小 batch 也稳定，训练更高效；
- SigLIP2 进一步加入自蒸馏、多分辨率等技巧，是当下 VLM 最常用的视觉骨干之一。

minimind-v 的具体选型：siglip2-base-p32-256-ve

- ViT-B/32 架构，~95M 参数，**全程冻结**，只做特征提取；
- 256×256 输入 → 64 个 patch token → 输出 64×768 特征；
- 只取 encoder 层输出（不需要它最终的对比学习嵌入向量）。


一个值得想的问题

SigLIP 训练的目标是"整图 ↔ 整段文本"的对齐，输出里每个 patch token 却携带着局部信息。VLM 复用它的 patch 级特征而不是整图向量 —— 为什么这样也行得通？（提示：注意力让 patch 之间交换过信息，且投影层与后续微调会进一步适配。）

分辨率是硬约束

256×256、64 个 token 意味着**每个 token 管 32×32 像素的区域**。小目标、图中文字在这个尺度下已经模糊 —— 这直接限制了检测定位精度与 OCR 能力（后面改进方向会再遇到它）。

② 投影层：把视觉特征“对齐”进语言空间



Projector 的职责：把视觉 token 的维度与分布映射到文本 embedding 所在的空间，让两种 token 可以在同一空间里被同一个 Transformer 处理 —— 这一步叫**跨模态特征对齐**。

方案演进：

- **LLaVA-1**：单层线性变换 —— 简单有效；
- **LLaVA-1.5**：2 层 MLP（Linear→GELU→Linear） —— 更强，成为事实标准；
- **BLIP-2**：Q-Former，用少量可学习 query 把视觉信息压缩成固定数量的 token；
- **minimind-v**：LayerNorm + 2 层 MLP（同 LLaVA-1.5 方案），~1M 参数。

Projector 参数极少，却是 VLM 里**第一个被训练、且必被训练**的模块。

③ 拼在一起：占位符替换机制（最关键的一步）



minimind-v 中这段核心逻辑（找到占位符位置、填入视觉特征）连同训练适配 < 50 行代码 —— 读源码时请一定找到它

先补一个概念：什么是“微调”（Fine-tuning）

迁移学习的直觉：


- 预训练模型 $\approx$ 已经完成“通识教育”的毕业生：语言、常识、视觉表征都已具备；
- 微调 $\approx$ **入职培训**：用少量领域数据、较小的学习率、较少的步数，让它适应具体岗位；
- 为什么不从头重训？数据贵、算力贵，而且会**破坏已有能力**（灾难性遗忘）。

微调的关键设计问题只有一个：**放开多少参数让它学？**

力度	可训参数	特点
全参微调	100%	上限最高；数据/显存需求大，遗忘风险大
冻结部分层	如只训首末层	保住主干能力，折中常用
只训新增模块	如 Projector	原模型零损耗，适配能力有限
LoRA	低秩旁路矩阵（ $<1\%$ ）	显存友好、可插拔，工业界标配

下一页的“两阶段训练”，就是这套“微调力度学”在 VLM 上的标准应用：不同阶段、不同模块，放开程度各不相同。

VLM 怎么训练：两阶段 + 冻结艺术



冻结策略的权衡（课程设计的重要实验变量）

策略	训练哪些参数	优点	风险 / 适用
只训 Projector	~1M	最省显存；LLM 能力零损耗	对齐程度有限；适合 Pretrain 阶段
解冻 LLM 首/末层 minimind-v 默认	Projector + LLM 第 1 层与最后 1 层	首层做跨模态融合、末层管回答风格，中间层保住语言知识	小模型 + 图文数据占比高时的稳妥折中
全参微调	LLM 全部参数	任务表现上限最高	需大数据+大显存；小模型易被图文梯度"洗掉"语言能力
LoRA	冻结主干，只训注入的低秩旁路矩阵	显存友好、可插拔、不破坏原权重	工业界最常用的折中手段

小模型（如 65M 的 minimind-v）视觉能力的上限，很大程度受制于**底座 LLM 的语言/推理能力**——"学外语"的上限取决于母语水平。把主干换成几 B 的 LLM，同样数据收益会明显变大。

目标
前置
原理
实现
实战

代表性 VLM 与主要改进方向

模型	特点
CLIP / SigLIP	图文对比学习，提供视觉编码器与零样本能力
BLIP-2	Q-Former 压缩视觉 token 数
LLaVA / 1.5	线性/MLP 投影的极简范式，教学首选
Qwen-VL 系列	支持检测框、OCR 等 定位类 输出
LLaVA-NeXT	动态分辨率 + 图像切片（tile）
MiniCPM-V / InternVL	小尺寸高性能代表

主要改进方向（可作报告"展望"素材）：

- **更高分辨率**：固定 256² 看不清细节 → 动态分辨率、tile 切片编码；
- **更强视觉编码器**：更细粒度特征、多编码器融合；
- **视觉 token 压缩**：缩短序列、降低推理成本；
- **视觉定位 Grounding**：输出坐标，打通检测/分割类任务（我们任务三的同款思想）；
- **多图与视频理解**：时序与跨图推理；
- **数据质量**：GPT-4o 等强模型合成高质量指令数据（蒸馏）。

共同点：**架构创新空间在收窄，数据与训练策略成为拉开差距的关键** —— 这也是课程设计把"数据集构建"放在目标第一位的原因。

目标
前置
原理
实现
实战

一页纸回顾：VLM 的全部要点



架构上，记住三句话

① 图像切 patch 就是 token；② 视觉 token 替换占位符后与文本完全同构；③ 编码器冻结、Projector 必训、LLM 看情况解冻。

训练上，记住三句话

① 先对齐（Pretrain，只训 Projector）后教任务（SFT）；② 数据质量比架构创新更拉开差距；③ 小模型的视觉上限受制于底座 LLM 的语言能力。

原理已经就绪。接下来的问题是：**怎么用这个架构去解决分类、问答、检测三个实际任务？**

↓ 进入第 ④ 讲：基于 VLM 实现三大任务

04

基于 VLM 实现三大任务

统一范式：图像 + 指令 → 文本生成

本讲路线：统一范式 → Prompt 设计规范 → 分类 / 问答 / 检测逐个落地 → 混成一份 SFT 数据

- 目标
- 前置
- 原理
- 实现**
- 实战

统一范式：一切皆生成

VLM 的输出永远是一段文本。三个任务的区别，只在于我们要求它生成什么内容、用什么格式：

任务	Prompt 示例	期望输出（文本）	解析与评测
分类	"图中主体属于以下哪个类别？[猫, 狗, 汽车...] 只回答类别名。"	金毛寻回犬	字符串归一化 → 精确匹配 → Accuracy
问答	"图中有几个人？他们在做什么？"	两个人，在草地上野餐。	EM / 关键词 / 人工评分
检测	"找出图中的狗，输出 [x1,y1,x2,y2]，0~1 归一化。"	[0.12, 0.34, 0.56, 0.78]	正则抽坐标 → 与真值算 IoU

关键① Prompt 设计

明确输出格式与取值范围，显著降低解析失败率（可作对比实验）。

关键② 输出解析

写鲁棒的解析器（正则/格式约束），统计 `format failure rate`。

关键③ 微调对齐

把任务数据转成指令格式做 SFT，让模型"学会"按格式回答 —— 提升最大的手段。

Prompt 设计规范：把任务“说清楚”

任务	✗ 含糊的 prompt	✓ 规范的 prompt
分类	"这是什么？" 答案空间开放，评测无法匹配	"图中主体属于以下哪个类别？[猫, 狗, 汽车...] 只回答类别名称。"
问答	"说说这张图。" 与问题无关的描述也算"回答了"	"图中有几个人？用一句话回答。"
检测	"框出狗。" 格式、坐标系、精度全部未定义	"定位图中的狗，输出 [x1,y1,x2,y2]，0~1 归一化，保留 3 位小数。"

① 输出格式显式化

模板、单位、小数精度都写进指令，解析器才有据可依。

② 答案空间封闭化

能做"选择题"就不做"开放题" —— 指标更客观，失败率更低。

③ 训练评测一致化

微调数据用的 prompt 必须与评测时同分布，否则指标失真、结论无效。

路线 A：零样本分类（不训练，先跑通）

做法：直接设计 prompt，把候选类别写进去，让模型"做选择题"：

```
<image>\n图中主体属于以下哪个类别？  
[飞机，汽车，鸟，猫，鹿，狗，青蛙，马，船，卡车]  
只回答类别名称。
```

为什么给候选列表？答案空间封闭 → 解析容易、评测客观；不给列表则是"开放分类"，更贴近真实使用但更难评测。两者都可以试，写进报告对比。

Prompt 工程小实验（报告素材）

- 有/无候选列表
- 中文 vs 英文 prompt
- "只回答类别名" vs 不加约束

观察零样本准确率与格式失败率对措辞的**敏感度** —— 小模型尤其敏感。


预期现象

minimind-v 的 SFT 数据是开放描述与问答，没专门学过"封闭式分类"，所以零样本分类可能：答对但啰嗦（"这是一只狗"）、或干脆不选列表里的词 —— 这正是微调要解决的问题。

路线 B：微调分类（把“分类头”藏进生成里）

微调数据： 答案固定为类别名的指令对（第 ① 讲已展示格式）。

评测流程：



报告里要做的对比：

- 零样本 vs 微调后 Accuracy（预期大幅提升）；
- 混淆矩阵：哪几类最容易混（如 猫↔狗）；
- 微调后回答是否变得“守规矩”（格式失败率 → ~0）。

思考点（写进报告）

生成式分类 vs 传统 softmax 分类头：本质区别是什么？生成式的优势（开放类别、可解释、多任务共享一个模型）与代价（推理慢、格式不可控）分别是什么？

问答：VLM 的"主场"，重点在数据与评测

minimind-v 开箱即可问答（SFT 数据本身就是百万级图文问答）。本任务的重点是**建一个属于你自己的评测集**：

- 选定一个**垂直场景**（校园照片 / 交通场景 / 商品图...），围绕图像设计问题；
- 问题类型覆盖：**属性**（什么颜色）、**计数**（有几个）、**空间关系**（A 在 B 左边吗）、**场景推断**（大概什么时间）；
- 每题 1~3 个参考答案，≥100 条；
- 可用强模型生成初稿再人工校对 —— 体验"数据蒸馏"。

是否微调自选：可以用自己场景的数据做一轮 SFT，观察领域适配效果。

评测：EM / 关键词命中率 / 人工评分（0/0.5/1）+ **按问题类型分桶**。

典型错误模式（错误分析框架）

模式	表现	可能原因
幻觉	描述图中不存在的内容	语言先验压过视觉证据
语言先验	不看图凭"常识"回答	视觉 token 权重不足
重复啰嗦	句子反复复读	小模型解码常见病症
答非所问	不遵循指令	指令理解能力弱


给每类错误配 1~2 个截图案例，是报告最出彩的部分。

检测：坐标也是文本，让模型“说出”框

核心思想：边界框的 4 个坐标，不过是 4 个数字 —— 数字也是 token，模型可以像说话一样把框“说”出来（Qwen-VL 与各类 Grounding 模型的标准做法）。

```
用户：<image>\n找出图中的狗，输出边界框，  
格式 [x1,y1,x2,y2]，0~1 归一化。  
助手：[0.122, 0.341, 0.563, 0.782]
```

- 坐标**归一化**到 0~1（或 0~999 整数），与图像分辨率解耦；
- 多目标：输出多个框，框与类别名配对；
- 此即**视觉定位（Visual Grounding）**：给文本描述，定位对应目标。



预测框 vs 真值框 → 算 IoU → Acc@IoU≥0.5

预期与心态

65M 小模型 + 256² 低分辨率，坐标**不可能很准**。看到“微调后 IoU 显著上升、框大致落在目标区域”就是成功。想一想：**64 个视觉 token、每个管 32×32 像素**，这个粒度如何限制定位精度？

补充：“坐标即文本”并非野路子，而是主流做法

工作	年份	做法
Pix2Seq (Google)	2021	首次把检测框坐标离散化为 token，目标检测变成纯粹的序列生成问题
OFA	2022	用统一序列生成框架覆盖 caption、VQA、检测、定位等 8 类任务
Qwen-VL	2023	指令微调中直接加入 <code><box>(x1,y1),(x2,y2)</box></code> 特殊格式，开源 VLM 定位能力的标杆
今天	2024+	Grounding（文本→坐标）已成 Qwen2.5-VL、InternVL 等主流 VLM 的标配能力

本课程设计的检测任务与工业界做法**完全同构**—— 同样的思想、同样的数据格式，只是我们的模型小了三个数量级。这也再次印证第 ③ 讲的观点：只要能变成 token 序列，任何问题都可以交给生成式模型。

目标
前置
原理
实现
实战

收尾：把三个任务混成一份 SFT 数据

```
# 每条样本 = conversations(json) + image_bytes(图像二进制)，存为 parquet

# 分类样本
[{"role": "user",      "content": "<image>\n图中主体属于哪个类别？只回答类别名。"},
 {"role": "assistant", "content": "狗"}]

# 问答样本
[{"role": "user",      "content": "图中有几个人？ <image>"},
 {"role": "assistant", "content": "两个人，正坐在草地上。"}]


# 检测样本
[{"role": "user",      "content": "<image>\n定位图中的狗，输出 [x1,y1,x2,y2] 归一化坐标。"},
 {"role": "assistant", "content": "[0.122, 0.341, 0.563, 0.782]"}]
```

- 同一模型、一次训练，学会三种“回答格式”—— 这就是 VLM 多任务范式的魅力；
- 建议混入少量通用问答/描述数据（防止过拟合、保持通用能力）—— 类比 minimind-v 在 SFT 中混入 23 万条纯文本对话的做法；
- 对比实验：**单任务分别微调 vs 三任务混合微调**，观察相互促进还是干扰。

- 目标
- 前置
- 原理
- 实现
- 实战

小结：从“三个任务”到“一种范式”

回看这一讲，三个任务其实共享同一条流水线：



这一讲的方法论

任何新任务来了，先问：答案能否写成文本？格式能否约束？指标能否自动计算？三个“能”，任务就能纳入 VLM 范式。

过渡到下一讲

范式已经清楚，还差最后一块拼图：**一台能亲手拆、亲手训的“真机器”**—— 够小、够透明、单卡跑得动。这就是 minimind-v。

05

minimind / minimind-v 实战

代码库结构 · 数据与训练 · 微调方法 · 动手路线

本讲路线：项目选型理由 → 架构细节（数字版） → 官方训练流程 → 五步动手路线 → 样板项目（真实数据 + 参照结果） → 微调要点与超参 → 避坑指南 → 答辩预演

目标

前置

原理

实现

实战

认识我们的实验平台：minimind 与 minimind-v

minimind（语言模型基座）

李生项目 [jingyaogong/minimind](#)：从 0 训练极小 LLM 的开源实现，含 tokenizer、预训练、SFT、LoRA、DPO 全流程。本课程使用其训练好的 `llm_768.pth`（768 隐藏维、8 层，~64M 参数）作为 VLM 的语言主干。

minimind-v（视觉拓展）


在 minimind 之上加视觉编码器 + 投影层，**核心算法改动 < 50 行**。65M 可训练参数（GPT-3 的 1/2600），**单张 3090 上 SFT 约 2 小时、成本约 3 元**。

为什么选它做课程设计？

- 代码**极简、无框架黑盒**：PyTorch 原生，每个环节都能读懂、能改；
- 算力门槛低：单卡 24G 可训练；
- 全流程自洽：数据格式 → 训练 → 推理 → WebUI 完整闭环；
- 架构与 LLaVA 等主流 VLM 思路一致，**学会它即学会一类**。

型号（2026-04 版本）：dense 65M / MoE 200M-A65M；视觉编码器 SigLIP2（~95M，冻结）；投影层 MLP（~1M）。

minimind-v 架构：带着数字再看一遍



输入端：prompt 中图像用 64 个 `<image_pad>` 占位：

请在代码里找到这三个位置（读源码作业）：

```
<image_pad> × 64 \n 这个图片描述的是什么内容？
```

文本查 embedding 后，用投影后的 64 个视觉 token 逐个替换占位符位置的 embedding，之后与纯 LLM 计算完全一致（第 ③ 讲的占位符替换图）。

- 视觉编码：`model/` 下 VLM 类中调用 SigLIP、取 **encoder 层输出**（不用最终对比嵌入）；
- 投影层：`vision_proj`（LayerNorm + 2 层 MLP）；
- embedding 替换逻辑：定位 `<image_pad>` 并填入视觉特征 —— 全程 < 50 行，务必亲手读一遍并画出数据流向图。

官方训练数据与两阶段流程

官方训练数据（ALLaVA-4V，中英双语）：

文件	规模	内容
<code>pretrain_i2t.parquet</code>	~127 万条	"描述这张图"式长 caption，用于视觉-语言对齐
<code>sft_i2t.parquet</code>	~290 万条	图像问答 + caption + 23 万条纯文本对话（保持语言能力）

格式：`conversations` + `image_bytes`，图像统一 256×256。SFT 已含 Pretrain 子集，快速复现可跳过 Pretrain。

两阶段训练与冻结策略：

阶段	脚本	冻结	lr
Pretrain（可选）	<code>train_pretrain_vlm.py</code>	<code>--freeze_llm 2</code> 只训 Projector	~4e-4
SFT（必需）	<code>train_sft_vlm.py</code>	<code>--freeze_llm 1</code> Projector + LLM 首末层	~5e-6

- `--freeze_llm`：0=全参 / 1=proj+首尾层 / 2=仅 proj —— 课程设计的重要对比变量；
- 支持断点续训 `--from_resume 1`、DDP 多卡、bf16 混合精度。

动手路线： 五步跑通课程设计

```
# ① 环境 (Python 3.10 + CUDA; 单卡 24G 即可)
git clone --depth 1 https://github.com/jingyaogong/minimind-v
pip install -r requirements.txt -i https://pypi.tuna.tsinghua.edu.cn/simple

# ② 下载资源: SigLIP2 视觉编码器 + MiniMind 语言主干 + 官方 VLM 权重
modelscope download --model gongjy/siglip2-base-p32-256-ve --local_dir ./model/siglip2-base-p32-256-ve
modelscope download --model gongjy/minimind-3v-pytorch --local_dir ./out

# ③ 先推理, 建立直观感受 (零样本跑通三个任务的 prompt)
python eval_vlm.py --load_from model --weight sft_vlm

# ④ 构建自己的三任务数据集 (转 parquet, 格式同 sft_i2t), 做 SFT 微调
python train_sft_vlm.py --epochs 2 --from_weight llm # 或基于官方 sft_vlm 权重继续微调

# ⑤ 评测与分析: 写解析+指标脚本, 对比微调前后, 写报告
```

- 第 ④ 步数据量小 (几百条) 时训练仅需几分钟到几十分钟;
- 可选加分项: WebUI 演示 (`scripts/web_demo_vlm.py`)、swanlab 训练曲线、LoRA 微调尝试。

- 目标
- 前置
- 原理
- 实现
- 实战

样板项目：mini-*v*lm @ PASCAL VOC

按上面的路线，我们在 **PASCAL VOC (2007+2012)** 上做了一个完整样板 —— 同一底座、多任务 SFT，**一个权重同时做三个任务**。把它当作你们作业的**参照基线**。

任务设定

VOC 20 类，一个模型通做：**生成式分类**、**模板化 VQA**（列举/计数/存在/定位）、**文本坐标检测**。

模型（与 minimind-*v* 一致）

SigLIP2 视觉编码器（冻结）→ MLP Projector(1M) → MiniMind LLM(64M)；可训练约 65M 参数。

训练开销

4× RTX 3090 + bf16，每个阶段仅 **5~15 分钟** —— 课程设计量级完全可复现。

数据集	训练	评测	构造方式
检测 voc_det	16,551	4,952	VOC 框标注 → 文本坐标（阅读顺序排序，剔除 difficult）
分类 voc_cls	8,790	3,192	只取 单类别 图像 → "主要物体是哪类（20 选 1）"
问答 voc_vqa	49,653	14,856	由检测 GT 模板生成 四类题（list/count/exist/locate，含负样本）
混合 voc_joint	75k / 33k	—	Stage-1 三任务混合；Stage-2 检测+定位强化

统一为 JSONL 对话格式，`<image>` 占位符由 tokenizer 替换为视觉 token —— 与讲义第 ① 讲的规范完全一致。

样板数据①：VOC 图像与三任务构造



多人 + 摩托车 + 椅子
(检测 / VQA 用图)



单类别图「猫」
(分类用图)



「羊」—— 检测单框样本

PASCAL VOC：20 个日常类别、约 2 万张带框标注图像，目标检测领域的“国民数据集”，规模适中、标注规范，非常适合课程设计。

从一份框标注，长出三种监督 (`scripts/prepare_voc_data.py` 一键生成)：

- 检测：XML 框标注 → 类别 `[x1,y1,x2,y2]` 文本，框按上→下、左→右排序（消除自回归顺序歧义）；
- 分类：筛出只含一类物体的图 → 20 选 1 的封闭式提问，答案即类别名；
- VQA：从检测 GT 自动出题 —— `list 有哪些物体` `count 有几个 X` `exist 有 X 吗` `locate X 在哪里`，并自动构造“没有 X”的负样本；
- 约定：坐标归一化到 0~1 保留三位小数；**difficult 物体剔除**（VOC 评测惯例）。

样板数据②：同一张图，三种监督信号



VOC2012 · 2010_005620.jpg (GT: 1 摩托车 + 8 人 + 1 椅子)

检测 · user

请检测图中的所有物体，输出类别和边界框坐标.....

检测 · assistant

摩托车 [0.766, 0.163, 0.822, 0.294]
人 [0.458, 0.244, 0.608, 0.672] (共 10 框)

VQA · exist

问：图中有人吗？ → 答：有，图中有 8 个人。

VQA · list

问：图中有哪些物体？ → 答：图中有 1 个摩托车、8 个人、1 个椅子。


分类数据则取**单类别**图像（如左页"猫"图）：问"主要物体属于哪个类别？（20 候选）" → 答"猫"。

样板结果：四个阶段，指标一路爬坡


阶段	视觉编码器	分类 acc (3192 张)	VQA acc (1200 条)	检测 F1@0.5 (1500 张)
Stage-1 三任务联合	P32 (64 tok)	96.24%	68.1%	0.312
Stage-2 检测+定位强化	P32 (64 tok)	95.96%	69.6% (locate 50.3%)	0.382 (meanIoU 0.714)
Stage-3 换高分辨率编码器	P16 (256 tok)	97.56%	46.6% *	0.425 (meanIoU 0.718)
Stage-4 全量联合回温 (最终)	P16 (256 tok)	97.56%	73.6% (locate 56.0%)	0.415 (meanIoU 0.722)

- * Stage-3 只用检测/定位数据训练，**count/list 题型被遗忘** —— 这是"灾难性遗忘"的生动案例；Stage-4 全量回温后恢复并反超；
- 最终模型 `voc_vlm4` 单一权重：分类 **97.6%** / VQA **73.6%** / 检测 F1 **0.415**；VQA 分题型：count 0.845 · exist 0.910 · list 0.630 · locate 0.560；
- 检测是 65M 小模型的明显短板 (P=0.42 / R=0.41) —— 这正好留给大家改进：你们的任务是**理解瓶颈在哪，而不是刷过这个数**。

样板结果：检测可视化与五条关键经验



较好的预测：框紧致、类别正确



典型失败：小物体漏检、重复框（FP 偏多）

绿框 = GT，红框 = 模型预测（同类预测已做 NMS 式去重 dedup 0.7）

消融得来的五条经验（每一条都可做你们的对比实验）：

- **坐标回归要放开全参数**：部分冻结时检测 F1 仅 0.03；全参 + lr 2e-5 才起步。分类/VQA 对冻结不敏感；
- **框按阅读顺序排列**（上→下、左→右）消除输出顺序歧义，合成数据上 F1 从 0.23 → 0.92；
- **检测强化阶段**（追加 det+locate 数据）提升检测与 locate 题，分类几乎不漂移；
- **视觉编码器空间分辨率是检测瓶颈**：P32 每 token 管 32×32 像素，小物体定位不准；换 P16（token 数 ×4）框明显更紧致；
- **同类预测去重**（NMS 式）能去掉重复框带来的 FP，评测脚本的解析与匹配同样影响指标。

微调要点与建议的对比实验

微调要点：

- **基座选择**：从 `llm`（纯语言权重）起步，或在官方 `sft_vlm` 上继续微调（推荐，省一轮对齐）；
- **冻结策略**：小数据微调建议 `--freeze_llm 1` 或 `2`，全参容易"洗掉"语言能力；
- **学习率**：小数据集用小 lr（1e-5 量级）+ 2~4 epoch，盯 loss 与 val 表现，警惕过拟合（训练集背下来、测试集不会）；
- **断点续训**： `--from_resume 1` 随时可中断恢复。

建议的对比实验（报告亮点，挑 2~3 组做扎实）：

对比项	观察什么
零样本 vs 微调后	格式遵循率、各任务指标跃升
freeze_llm = 0/1/2	任务指标 vs 通用能力保持
不同 prompt 表述	零样本性能对措辞的敏感度
单任务 vs 多任务混合	任务间促进还是干扰
数据量 50/200/500	数据规模的学习曲线

超参速查表与训练信号解读

小数据微调（~200~500 条）建议起点：

超参	建议值	说明
<code>--freeze_llm</code>	1 或 2	先 2 跑通，再试 1 看提升
学习率	1e-5 ~ 5e-6	小数据宁小勿大
<code>--epochs</code>	2 ~ 4	盯 val，过拟合就减
batch_size	显存内尽量大	配合梯度累积
max_seq_len	默认即可	检测样本坐标长，别截断

训练可视化：加 `--use_wandb`（默认走 swanlab），曲线实时可查。

Loss 曲线三种形态：

平稳下降后趋平

✔ 正常。结合 val 指标确认收益即可。

train 降、val 升（或不动）

过拟合：模型在背训练集。对策：减 epoch、降 lr、加数据、加强冻结。

从头到尾纹丝不动

先查数据格式（占位符、列名、role 字段），再查 lr 是否过小、参数是否全被冻结。

避坑指南：六个高频问题

模型答非所问 / 不守格式

检查 prompt 是否与训练时表述一致；微调数据里答案格式是否统一；`<image>` 占位符是否漏写。

微调后反而"变傻"

典型灾难性遗忘：任务数据占比过高或 lr 过大。改 `--freeze_llm 1/2`、混入通用对话数据、降 lr。

检测坐标完全不对

先确认输出**格式**正确（能解析出 4 个数）再谈精度；检查归一化约定；256² 分辨率下小目标本就难，属预期现象。

重复啰嗦 / 停不下来

小模型常见。调低 `temperature`、增大 `repetition_penalty`（如 1.2）；也是错误分析的好素材。

显存不足

减小 `batch_size` + 梯度累积；缩短 `max_seq_len`；确认视觉编码器已冻结。

数据格式踩坑

用仓库 `dataset/lm_dataset.py` 预览自己的 parquet 前 5 条；确认列名、role 字段、图像字节流与官方样例一致。

这门课程设计要带走什么

知识层面

- 三大 CV 任务的定义、数据与评测方法
- Transformer 与「一切皆 token」的统一视角
- VLM 三段式架构：编码器 / 投影 / LLM
- 两阶段训练与冻结策略的设计权衡

能力层面

- 把**任意任务**转化为「图像+指令→文本」的范式思维
- 数据集构建、标注规范与评测脚本设计的完整经验
- 读懂并魔改一个极简但完整的开源 VLM 项目
- 实验对比设计与错误分析的方法论

「用乐高拼出一架飞机，远比坐在头等舱里飞行更让人兴奋。」—— 不要满足于调用 API，亲手把这个 65M 的小模型拆开、训练、玩坏，你就真正理解了 VLM。

答辩预演：老师可能会问的 6 个问题

Q1 为什么视觉编码器全程冻结？

提示：预训练成本、表征通用性、与 CLIP 对齐空间的关系。

Q2 `<image_pad>` 在前向计算里发生了什么？

提示：先查 embedding 表，再被视觉 token 逐个替换。

Q3 检测坐标为什么要归一化？

提示：与输入分辨率解耦；输出分布稳定、易于学习。

Q4 format failure rate 高说明什么？怎么降？

提示：指令遵循能力不足；prompt 显式化 + 格式统一的 SFT 数据。

Q5 `freeze_llm` 0/1/2 怎么选？依据是什么？

提示：底座大小、图文数据占比、灾难性遗忘。

Q6 你的模型最大的瓶颈是什么？怎么改进？

提示：分辨率与视觉 token 数、底座语言能力、数据规模。

能把这 6 题答清楚，本课程设计的核心目标就达到了。

参考资料

代码与数据

- minimind-v: github.com/jingyaogong/minimind-v
- minimind (LLM 基座): github.com/jingyaogong/minimind
- 训练数据: HuggingFace / ModelScope [jingyaogong/minimind-v_dataset](#) (源自 ALLaVA-4V)
- 视觉编码器: [siglip2-base-p32-256-ve](#)

工具: Labelme / CVAT (标注)、swanlab (训练可视化)

论文

- Attention Is All You Need (Transformer, 2017)
- CLIP: Learning Transferable Visual Models From Natural Language Supervision (2021)
- BLIP-2 (2023) / LLaVA (2023) / LLaVA-1.5 (2023)
- Faster R-CNN (2015) / YOLO 系列 / DETR (2020)
- VQA: Visual Question Answering (2015)

祝同学们玩得开心，期待看到大家的错误分析与创意实验！